



Received 00th January 20xx
Accepted 00th February 20xx
Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

Analisis dan Peramalan Tingkat Inflasi Indonesia Menggunakan Model ARCH

Meinisa^a, Maria Gresia Hutabarat^b, Josua Alfa Viando Panggabean^c, Putri Intan Kirani^d, Rizki Adrian Bennovry^e, Ibnu Farhan Al-Ghifari^f

^a 121450076

^b 121450057

^c 121450061

^d 121450055

^e 121450073

^f 121450121

* Corresponding E-mail: journal@itera.ac.id

Abstract: *This study aims to analyze and predict the inflation rate in Indonesia from January 2020 to December 2023 by utilizing ARIMA and ARCH models. Monthly inflation data from Bank Indonesia reflects a 36-month pattern of change, which shows significant fluctuations and requires stationarity and volatility modeling to make appropriate predictions. Initial data processing is done in the analysis process, followed by stationarity test using ADF (Augmented Dickey-Fuller) Test, and ARIMA modeling to recognize autoregressive and moving average components. In the next step, the ARCH model is used to identify the conditional heteroscedasticity pattern, which indicates different fluctuations in inflation volatility over time. The analysis shows that the ARIMA (3,1,0) model has the lowest AIC and BIC values, so it is chosen as the best model. The ARCH model successfully recognizes the volatility clustering pattern, where a period of high volatility is followed by another period of high volatility. Assessment with MAE, RMSE, and MAPE shows that combining ARIMA and ARCH models produces more stable and precise inflation prediction, which can help monetary policy in dealing with future inflation fluctuations in Indonesia.*

Keywords: ARIMA, ARCH, inflation forecasting, volatility clustering, time series.

Abstrak: Penelitian ini bertujuan untuk menganalisis dan memprediksi tingkat inflasi di Indonesia dari Januari 2020 hingga Desember 2023 dengan memanfaatkan model ARIMA dan ARCH. Data inflasi bulanan dari Bank Indonesia mencerminkan pola perubahan selama 36 bulan, yang menunjukkan fluktuasi yang signifikan dan memerlukan pemodelan stasioneritas serta volatilitas untuk membuat prediksi yang tepat. Pemrosesan data awal dilakukan dalam proses analisis, diikuti dengan uji stasioneritas menggunakan Uji ADF (Augmented Dickey-Fuller), dan pemodelan ARIMA untuk mengenali komponen autoregressive dan moving average. Langkah berikutnya, model ARCH digunakan untuk mengidentifikasi pola heteroskedastisitas bersyarat, yang menunjukkan fluktuasi volatilitas inflasi yang berbeda-beda dari waktu ke waktu. Analisis menunjukkan bahwa model ARIMA (3,1,0) memiliki nilai AIC dan BIC paling rendah, sehingga dipilih sebagai model terbaik. Model ARCH sukses mengenali pola clustering volatilitas, dimana periode volatilitas tinggi diikuti oleh periode volatilitas tinggi lainnya. Penilaian dengan MAE, RMSE, dan MAPE menunjukkan bahwa menggabungkan model ARIMA dan ARCH menghasilkan prediksi inflasi yang lebih stabil dan tepat, yang dapat membantu kebijakan moneter dalam menghadapi fluktuasi inflasi di masa yang akan datang di Indonesia.

Kata Kunci : ARIMA, ARCH, peramalan inflasi, volatility clustering, deret waktu.



Pendahuluan

Inflasi merupakan salah satu indikator penting yang mencerminkan stabilitas ekonomi suatu negara. Di Indonesia, tingkat inflasi menjadi perhatian utama bagi pemerintah dan Bank Indonesia, karena dampaknya yang luas terhadap kesejahteraan masyarakat dan pertumbuhan ekonomi. Perubahan tingkat inflasi dapat mempengaruhi daya beli masyarakat, stabilitas nilai tukar, serta kepercayaan investor dalam jangka panjang. Oleh karena itu, peramalan tingkat inflasi sangat penting untuk membantu pengambil kebijakan dalam merancang langkah-langkah yang tepat guna menjaga stabilitas ekonomi.

Salah satu metode yang dapat digunakan untuk menganalisis dan meramalkan inflasi adalah model ARCH (Autoregressive Conditional Heteroskedasticity). Model ini cocok untuk menganalisis data deret waktu dengan volatilitas yang berfluktuasi, seperti yang sering terjadi pada tingkat inflasi. Model ARCH mampu menangkap perubahan dalam volatilitas data dari waktu ke waktu, yang berguna untuk memahami pola ketidakpastian dalam pergerakan inflasi. Dengan menggunakan model ini, pengambil kebijakan dapat memperoleh gambaran yang lebih akurat tentang fluktuasi inflasi di masa mendatang.

Penelitian ini bertujuan untuk menganalisis dan memprediksi tingkat inflasi di Indonesia dengan menggunakan model ARCH. Melalui pendekatan ini, diharapkan dapat dihasilkan peramalan inflasi yang lebih andal, sehingga membantu pemangku kepentingan dalam merumuskan kebijakan yang responsif terhadap dinamika ekonomi yang terjadi di Indonesia.

Metode

1. Deskripsi Dataset

Data yang digunakan dalam penelitian ini diperoleh dari Bank Sentral Republik Indonesia yang menyediakan informasi mengenai tren suku bunga bulanan di Indonesia dari April 2016 hingga Oktober 2024. Data ini terdiri dari dua kolom, yaitu kolom Bulan yang menunjukkan bulan serta tahun dari setiap pengamatan, dan kolom Suku Bunga (%) yang mencatat nilai suku bunga dalam persentase yang berlaku pada setiap bulan tersebut. Dataset ini penting dalam memantau perkembangan suku bunga, yang merupakan salah satu indikator ekonomi utama yang

digunakan untuk mengukur dampak dari kebijakan moneter dan stabilitas ekonomi.

Tabel 1. Dataset Tingkat Inflasi di Indonesia Tahun 2020-2023

Bulan	Suku Bunga(%)
April 2016	5.50
Mei 2016	5.50
Juni 2016	5.25
Juli 2016	5.25
Agustus 2016	5.25
...	...
Juli 2024	6.25
Agustus 2024	6.25
September 2024	6.00
Oktober 2024	6.00

Dalam dataset ini, suku bunga terendah tercatat pada 3,50% dan tertinggi mencapai 6,00%. Perubahan ini memberikan wawasan mengenai dinamika ekonomi yang terjadi dalam kurun waktu delapan tahun terakhir. Secara keseluruhan, data ini bermanfaat untuk analisis tren, identifikasi pola fluktuasi suku bunga, dan studi dampak kebijakan suku bunga terhadap perekonomian. Dataset ini sangat berharga sebagai dasar untuk melakukan proyeksi atau peramalan tingkat suku bunga di masa depan serta memahami keterkaitannya dengan pertumbuhan ekonomi, inflasi, dan stabilitas keuangan.

2. Pemodelan ARIMA (Autoregressive Integrated Moving Average)

Metode ARIMA (Autoregressive Integrated Moving Average) adalah salah satu pendekatan dalam analisis deret waktu dengan menggabungkan dua komponen utama autoregressive (AR) dan moving average (MA), berikut komponen yang terdapat pada pemodelan ARIMA :

1. Autoregressive (AR)

Komponen AR dalam model ARMA mengasumsikan bahwa nilai saat ini dari variabel bergantung secara linear pada nilai sebelumnya, yaitu nilai lag dari variabel yang sama. Ini dapat digambarkan sebagai proses di mana variabel masa lalu mempengaruhi variabel saat ini melalui koefisien autoregressive.

- Order AR (p), Order dari komponen AR ditentukan oleh jumlah lag yang digunakan. Misalnya, model AR(1) menggunakan satu nilai lag, AR(2) menggunakan dua nilai lag, dan seterusnya.
- Komponen AR dari model ARMA (p) dapat dinyatakan sebagai:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t$$

Dimana y_t adalah nilai observasi pada waktu t , $\phi_1, \phi_2, \dots, \phi_p$, adalah koefisien autoregressive, dan ϵ_t adalah error pada waktu t .

- Koefisien autoregressive ϕ merepresentasikan pengaruh observasi masa lalu terhadap nilai saat ini. Jika nilai ϕ_1 mendekati 1, maka ada ketergantungan kuat antara observasi sekarang dan sebelumnya.

2. Moving Average (MA)

Komponen MA menangani hubungan linear antara nilai sekarang dan error masa lalu. Error yang dimaksud di sini adalah deviasi antara nilai yang sebenarnya dan nilai yang diprediksi oleh model di masa lalu.

- Order MA (q), Komponen MA pada model ARMA melibatkan order q, yang mengacu pada jumlah error masa lalu yang digunakan untuk memperkirakan nilai saat ini.
- Komponen MA dari model ARMA (q) dinyatakan sebagai:

$$y_t = \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q} + \epsilon_t$$

Dimana $\theta_1, \theta_2, \dots, \theta_q$ adalah koefisien moving average, dan ϵ_t adalah error sekarang.

- Interpretasi Koefisien θ dalam komponen MA menunjukkan kontribusi dari error masa lalu dalam mempengaruhi nilai saat ini. Besar kecilnya error masa lalu berperan penting dalam prediksi nilai berikutnya.

3. Differencing (I)

Differencing digunakan untuk membuat data stasioner, dimana differencing pertama didefinisikan sebagai:

$$Y_t'' = Y_t - Y_{t-s}$$

Untuk differencing musiman dengan orde D, differencing dilakukan pada interval musiman S

3. Model GARCH (Generalized Autoregressive Conditional Heteroskedasticity)

Model ARCH adalah model statistik yang digunakan untuk menganalisis dan meramalkan volatilitas dalam data deret waktu, khususnya di sektor keuangan[4]. Model ini sangat efektif dalam menangani perubahan varians yang berfluktuasi atau dikenal dengan heteroskedastisitas, yang sering kali terjadi pada data seperti harga saham atau nilai tukar mata uang. Dalam sebuah penelitian, GARCH sering dimanfaatkan di pasar modal untuk mengukur risiko volatilitas harga saham, contohnya dengan menggunakan data seperti Indeks Harga Saham Gabungan (IHSG)[5]. Di Indonesia, model GARCH telah diterapkan dalam berbagai studi untuk memahami pengaruh krisis keuangan terhadap volatilitas IHSG, dengan tujuan untuk memodelkan pola volatilitas yang sering muncul secara berkelompok (clustering) dalam periode tertentu.

1. Parameter Utama

- Model rata-rata (Mean Equation)

$$y_t = \mu + \epsilon_t$$

Keterangan:

yt : nilai pengamatan pada waktu t

μ : rata rata

ϵ_t : error term pada waktu t

- Model Varians (Variance Equation)

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2$$

Keterangan:

σ_t^2 : varians pada waktu t

α_0 : konstanta yang harus positif

α_i : parameter model ARCH yang menunjukkan pengaruh dari residual sebelumnya (harus non-negatif)

β_j : parameter GARCH yang mengukur dampak dari varians lag pada varians saat ini

p : orde dari model GARCH

q : orde dari model ARCH

2. Estimasi Parameter

Model GARCH biasanya diestimasi dengan metode Maximum Likelihood Estimation (MLE) untuk menemukan parameter α dan β yang terbaik. Aplikasi utama GARCH banyak ditemui dalam:

- Estimasi Risiko: Pengukuran volatilitas pada harga saham, mata uang, atau komoditas.
- Prediksi Volatilitas: Membantu investor atau manajer risiko untuk memprediksi volatilitas di masa depan.

Model GARCH bisa diperluas menjadi varian lain seperti GARCH-M, EGARCH, dan TGARCH, yang menambahkan parameter untuk menangani perilaku volatilitas yang asimetris atau mengkomodasi efek leverage.

4. Tahapan Utama Pemodelan GARCH

1. Pengunduhan dan Pemrosesan Data

Tahapan awal dalam penelitian ini adalah pengunduhan suku bunga Bank Indonesia dari sumber resmi, seperti situs Bank Indonesia. Setelah berhasil mengunduh, data dimuat ke dalam R menggunakan fungsi yang sesuai. Proses pembersihan data dilakukan untuk menghilangkan baris atau kolom yang tidak relevan dan memeriksa adanya nilai yang hilang. Data kemudian diubah menjadi format time series, memastikan bahwa informasi terstruktur dengan baik dan siap untuk analisis lebih lanjut.

2. Pemeriksaan Stasioneritas Data

Setelah data siap, langkah berikutnya adalah melakukan pemeriksaan stasioneritas. Uji ADF (Augmented Dickey-Fuller) diterapkan untuk menentukan apakah data time series bersifat stasioner. Jika hasil uji menunjukkan bahwa data tidak stasioner, transformasi seperti differencing dilakukan untuk mencapai stasioneritas yang diperlukan. Proses ini penting agar model yang dibangun dapat memberikan hasil yang valid dan akurat.

3. Pemodelan ARIMA

Dengan data yang telah memenuhi syarat stasioneritas, penelitian berlanjut ke pemodelan ARIMA. Analisis ACF (Autocorrelation Function) dan PACF (Partial Autocorrelation Function) dilakukan untuk mengidentifikasi parameter model yang sesuai. Setelah menentukan parameter, model ARIMA diestimasi, dan evaluasi model dilakukan dengan memeriksa residual untuk memastikan tidak ada pola autocorrelation yang tersisa. Langkah ini penting untuk memastikan bahwa model ARIMA dapat menjelaskan data dengan baik.

4. Uji Diagnostik Model

Eksplorasi Residual, sisaan model diperiksa menggunakan Q-Q plot, residuals plot, serta ACF dan PACF plot, untuk memastikan bahwa sisaan berdistribusi normal, acak, dan bebas dari autokorelasi.

Uji Formal Residual:

- Uji Normalitas: Uji Jarque-Bera dan Shapiro-Wilk dilakukan untuk memeriksa apakah sisaan model berdistribusi normal.
- Uji Keterbebasan Residual: Uji Ljung-Box dilakukan untuk memverifikasi bahwa tidak ada autokorelasi pada sisaan, yang menunjukkan bahwa model tidak memiliki pola tertentu pada residual.
- Uji Nilai Tengah Residual: Menggunakan uji t-test untuk memastikan bahwa nilai rata-rata dari sisaan adalah nol.

5. Peramalan


Model ARIMA yang terpilih digunakan untuk memproyeksikan suku bunga dalam periode ke depan ($h=12$). Hasil peramalan kemudian dibandingkan dengan data aktual menggunakan matriks akurasi. Peramalan Rata-Rata dan Ragam dengan GARCH untuk memodelkan volatilitas dari data yang memiliki variabilitas tinggi, memungkinkan estimasi *variance forecasting* yang dapat digunakan untuk mengukur risiko dan ketidakpastian.

6. Evaluasi Akurasi Model

Tahapan akhir adalah evaluasi akurasi model. Metrik seperti MAE (Mean Absolute Error), RMSE (Root Mean Square Error), dan MAPE (Mean Absolute Percentage Error) dihitung untuk memberikan gambaran tentang seberapa baik

model dalam memperkirakan inflasi. Penggunaan fungsi-fungsi yang tersedia dalam R memudahkan perhitungan metrik ini. Melalui evaluasi ini, penelitian tidak hanya menghasilkan model peramalan yang handal tetapi juga memberikan wawasan yang berarti tentang tren inflasi di Indonesia.

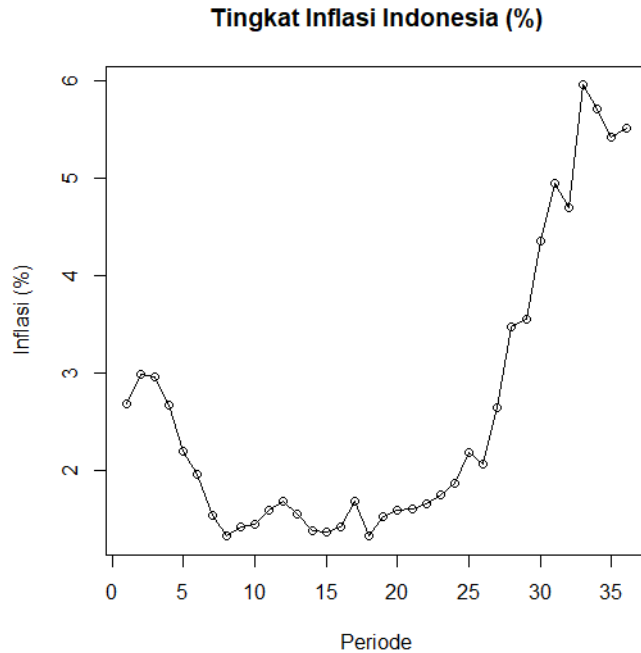
Hasil dan Pembahasan



Tingkat Inflasi Indonesia (%) 2020-2023

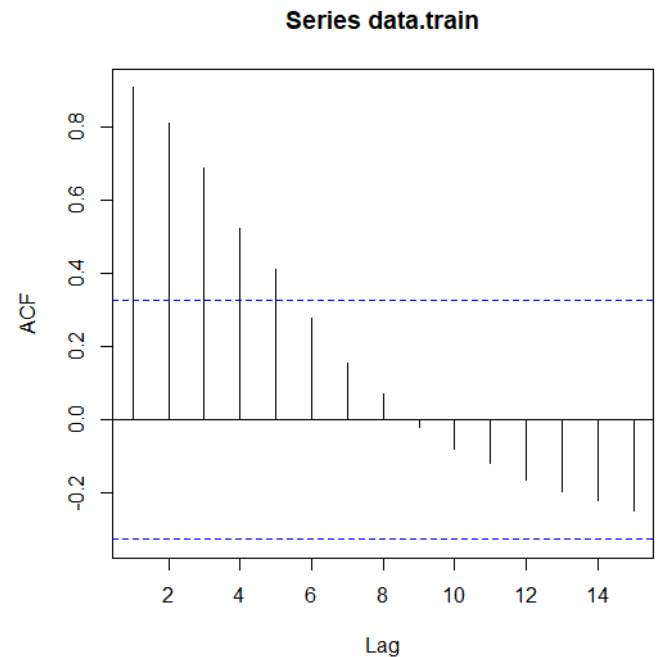
Gambar 1. Boxplot Tingkat Inflasi Indonesia Pada Tahun 2020 - 2023

Gambar 1 menunjukkan Boxplot pada tingkat inflasi Indonesia dari tahun 2020 hingga 2023. dari gambar boxplot diatas diperoleh median sekitar 3%. terdapat kuartil bawah (q_1), kuartil tengah (q_2), dan kuartil atas (q_3), yang masing masing kuartil berada di 2%, sekitaran 2,5% sampai 4%. selain median dan kuartil, terdapat nilai minimum yakni 1% dan nilai maksimum 6%. angka 1% hingga 6% menunjukkan inflasi yang dialami oleh Indonesia dari tahun 2020 hingga 2023. garis vertikal pada boxplot gambar 1 merupakan garis yang memberikan informasi mengenai data minimum dan data maksimumnya.



Gambar 2. Plot Time Series Tingkat Inflasi Indonesia Pada Tahun 2020 - 2023

Berdasarkan Gambar 2 menunjukkan Plot Time series pada tingkat Inflasi Indonesia pada tahun 2020-2023. sumbu x merupakan waktu atau periode dari tahun 2020 hingga 2023, sementara itu sumbu y merupakan persentase tingkat inflasi(dalam gambar 2 , inflasi terjadi di rentang 1% hingga 6%) selama periode yang ditunjukkan oleh sumbu x. grafik pada gambar ini memiliki tren yang stabil di awal namun terus mengalami peningkatan secara signifikan. hal ini dapat dilihat, tingkat inflasi mengalami penurunan dari 3% menjadi 1 %, lalu bergerak naik 2% hingga 3% di pertengahan waktu (sumbu x), dan terus mengalami kenaikan dari 3% hingga 6%. tren yang terdapat di dalam grafik, menunjukkan bahwa inflasi yang terjadi lebih besar di akhir periode, tentunya dapat disebabkan oleh faktor faktor eksternal yang mempengaruhi lonjakan tajam di akhir periode.



Gambar 3. Plot ACF dari Data Training Tanpa *Differencing*


Gambar 3 menunjukkan Plot ACF (*Autocorrelation Function*) dari data tingkat inflasi (%) di Indonesia pada tahun 2020 - 2023 sebelum dilakukannya *differencing*. Plot ini mendeskripsikan hubungan suatu nilai dalam periode saat ini dan nilai pada periode sebelumnya. Pada bagian atas menggambarkan hubungan korelasi data jumlah angkutan barang dengan lag tertentu. Pada plot ini, beberapa batang (lag) berada di luar batas signifikansi yang ditunjukkan dengan garis biru putus-putus, yang menandakan adanya korelasi signifikan antar periode tertentu. Terlihat bahwa terdapat lebih dari tiga lag pertama yang signifikan sehingga mengindikasikan data belum stasioner terhadap rata-rata.

Tabel 2 Uji Stasioner dengan Uji ADF Tanpa *Differencing*

Nilai Uji ADF	Lag Order	P-Value
1.451	0	0.959

Hasil pengujian stasioner menggunakan Uji ADF tanpa adanya *differencing* ditunjukkan oleh tabel 2. Nilai uji ADF diperoleh nilai sebesar 1.451, nilai pada hasil pengujian ini

menunjukkan bahwa data tidak mendekati sifat stasioner. Lalu p-value nya sebesar 0.959, angka ini lebih besar dari 0.05 maka keputusan yang diperoleh adalah menolak H_0 . Berdasarkan hasil diatas dapat ditarik keputusan bahwa data tersebut merupakan data non-stasioner dan perlu dilakukannya *differencing*.




Gambar 4. Plot Time Series Tingkat Inflasi Indonesia Pada Tahun 2020 - 2023 Setelah *Differencing* 1 Kali

Gambar 4 menunjukkan grafik plot time series pada tingkat inflasi yang dialami oleh Indonesia pada tahun 2020 - 2023 dengan melakukan differencing 1 kali. sumbu x merupakan waktu atau periode dari tahun 2020 - 2023. sementara itu sumbu y merupakan tingkat inflasi yang dialami Indonesia setelah dilakukan differencing 1 kali. dalam tahap sebelumnya, didapatkan data pada grafik 3 yang belum stasioner, sehingga pada grafik 4 data inflasi akan diolah kembali agar menjadi stasioner dengan perlakuan differencing sebanyak 1 kali. berdasarkan grafik pada gambar 4 terlihat bahwa data sudah stasioner terhadap rata rata. pada periode 30 - 35 menunjukkan tingkat inflasi yang signifikan.

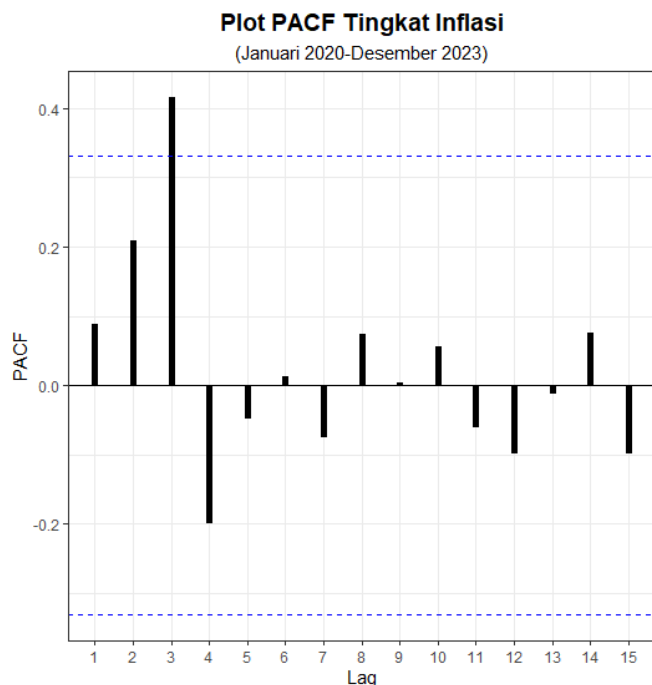
Plot ACF Tingkat Inflasi

(Januari 2020-Desember 2023)



Gambar 5. Plot ACF Tingkat Inflasi Indonesia Pada Tahun 2020 - 2023 Setelah *Differencing* 1 Kali

Gambar 5 menunjukkan plot ACF yang telah mengalami *differencing* sebanyak 1 kali. Diperoleh hasil bahwa nilai autokorelasi pada beberapa lag signifikan, namun beberapa lagi mendekati nol. Hasil dari pergerakan garis dalam grafik pada Gambar 5 menunjukkan bahwa *differencing* telah mengurangi autokorelasi pada lag yang lebih tinggi apabila dibandingkan dengan sebelumnya. Pada ke-3 memiliki nilai autokorelasi yang besar (signifikan) kemudian menurun. Ini menunjukkan bahwa ada keterkaitan hingga beberapa lag awal, yang dapat mengindikasikan komponen *moving average* (MA) pada model ARIMA. Karena ACF terpotong pada lag ke-3, model MA(3) mungkin cocok.



Gambar 6. Plot PACF Tingkat Inflasi Indonesia Pada Tahun 2020 - 2023 Setelah *Differencing* 1 Kali

Hasil yang ditunjukkan pada Gambar 6 yaitu plot *Partial Autocorrelation Function* (PACF) merupakan grafik yang menunjukkan korelasi parsial antara nilai dalam deret waktu dan nilai lag nya. Nilai PACF terlihat signifikan hingga lag 3, lalu cepat menurun. Ini mengindikasikan adanya komponen *autoregressive* (AR) hingga lag ke-3. Model AR(3) mungkin cocok berdasarkan pemotongan ini.

Tabel 3 Uji Stasioner dengan Uji ADF Dengan *Differencing* 1 kali

Nilai Uji ADF	Lag Order	P-Value
-5.10	0	0.01

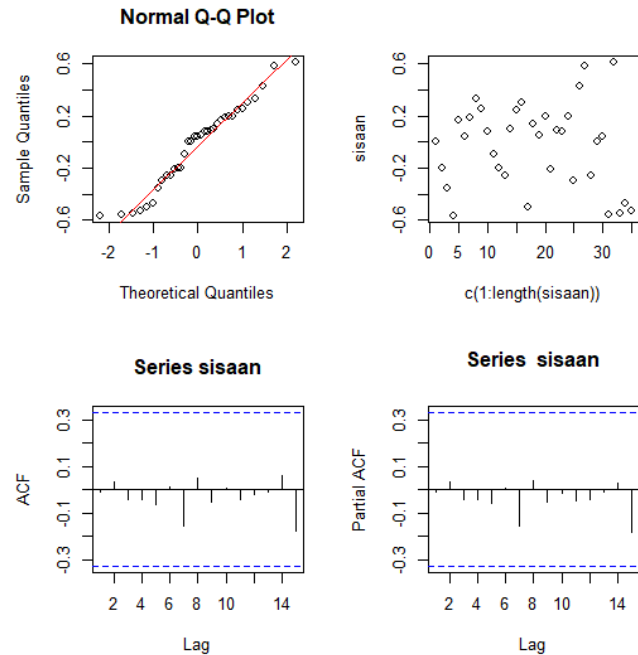
Hasil pengujian stasioner menggunakan Uji ADF dengan *Differencing* sebanyak 1 kali, ditunjukkan oleh Tabel 3. Nilai uji ADF diperoleh nilai sebesar -5.10 dari yang sebelumnya 1.451. Perlakuan dengan menambah *differencing* 1 kali agar

data yang diperoleh nantinya adalah data bersifat stasioner. Lag order 0 mengindikasikan bahwa tidak terdapat penambahan pada uji ADF nya, dan p-value nya adalah 0.01. Angka ini lebih besar dari 0.05 maka keputusan yang diperoleh adalah menerima H_0 , berdasarkan hasil tersebut dapat ditarik keputusan bahwa data tersebut sudah stasioner setelah dilakukan uji ADF.


Tabel 4 Nilai AIC dan BIC Dengan Berbagai Model ARIMA

ARIMA (p,d,q)	AIC	BIC
ARIMA (0,1,0)	51.63148	53.15784
ARIMA (0,1,3)	35.40214	41.50758
ARIMA (3,1,0)	29.70217	35.80761
ARIMA (3,1,3)	33.02433	43.70886

Berdasarkan Tabel 4, model ARIMA (3,1,0) memiliki nilai AIC dan BIC yang paling rendah yakni untuk AIC sebesar 29.70217 Sedangkan BIC adalah 35.80761. Arima (3,1,0) dipilih karena memiliki nilai paling rendah dibandingkan dengan model lainnya hal ini menunjukkan kesetaraan yang baik diantara fit dan kompleksitas masing masing model.

**Gambar 7.** Hasil Uji Diagnostik

Berdasarkan grafik 7 menunjukkan hasil uji diagnostik tingkat inflasi indonesia dari tahun 2020 hingga 2023. plot normal q-q plot pada gambar memberikan gambaran kuartil residual terhadap kuartil teoritis, titik titik dalam gambar tersebut mengikuti garis merah, hal ini berarti residual berdistribusi dengan normal. gambar kedua pada grafik 7 merupakan plot residual dengan indeks, adapun fungsi dari plot ini adalah untuk memastikan variansi pada tingkat inflasi yang dialami indonesia pada tahun 2020 hingga 2023 adalah tetap (konstan). titik titik tersebar secara acak dan bebas, hal ini menunjukkan bahwa data memiliki tersebar dengan konstan. gambar selanjutnya adalah gambar pada plot fungsi autokorelasi (ACF), pada gambar titik pada garis cenderung mendekati nol. terakhir, ditunjukkan oleh gambar plot fungsi autokorelasi parsial (PACF), untuk mengukur relasi yang terjadi diantara kedua residual dengan memperkirakan waktu jedanya. berdasarkan gambar ke 4 pada grafik 7, grafik menunjukkan tidak adanya autokorelasi yang signifikan.

**Gambar 8.** Plot Hasil Peramalan Tingkat Inflasi Indonesia

Berdasarkan Gambar 8 , didapatkan plot hasil peramalan tingkat inflasi di indonesia dari tahun 2020 hingga 2023 dengan menggunakan pemodelan ARIMA(3,1,0). garis berwarna hitam pada gambar menunjukkan data historis tingkat inflasi. menggunakan model ARIMA(3,1,0) dengan lag sampai 4 periode ini, menghasilkan peramalan tingkat inflasi yang diramalkan mengalami kenaikan atau mengikuti tren tertentu.

Tabel 5 Perbandingan Nilai Aktual dan Nilai Hasil Forecast Dari Data Testing Menggunakan ARIMA (3,1,0)

Data	Nilai Aktual	Nilai Forecast
1	5.28	5.372
2	5.47	5.292
3	4.92	5.331
4	4.33	5.279
5	4	5.277

Berdasarkan Tabel 5, diperoleh hasil bahwa pemodelan dengan menggunakan ARIMA (3,1,0) bervariasi dalam melakukan akurasi prediksi khususnya untuk data testing. Nilai perbandingan antara nilai aktual dan nilai peramalan (*forecasting*) sangat bervariasi tetapi tidak jauh berbeda, jika menggunakan metode ARIMA (3,1,0). Misalnya dari 5


data diperoleh hasil berturut turut untuk nilai aktualnya sebesar 5.28, 5.47, 4.92, 4.33, dan 4. Sementara itu pada nilai *forecasting* didapat hasil berturut turut yakni 5.372, 5.292, 5.331, 5.279, dan 5.277.

Tabel 6 Ringkasan Analisis Volatilitas dengan Model ARCH

Analisis	Parameter	Nilai	P-Value
Model Rata-Rata	Intercept	0.08086	0.208
Model Varians (ARCH)	Intercept	0.13131	0.0168
Model Varians (ARCH)	L(ehatsq)	0.04685	0.793
ARCH Test (Lag 1)	Chi-Squared	-	0.074
ARCH Test (Lag 2)	Chi-Squared	-	1.10
Model GARCH (0,1)	a0	0.13	2.6e
Model GARCH (0,1)	a1	0.10	0.681
Tes Diagnostik	Jarque-Bera	14.16	0.0008
Tes Diagnostik	Box-Ljung	0.022	0.88

Berdasarkan Tabel 6 dapat dilihat hasil analisis terkait perilaku volatilitas dari data tingkat inflasi di Indonesia. Pertama, dalam analisis model rata-rata nilai intercept ditemukan sebesar 0.08086 dengan p-value sebesar 0.208, yang menunjukkan bahwa tidak ada bukti signifikan bahwa rata-rata perubahan data berbeda dari nol. Ini mengindikasikan bahwa data tidak menunjukkan pola yang jelas di sekitar rata-rata. Selanjutnya, pada analisis varians menggunakan model ARCH, intercept diperoleh sebesar 0.13121 dengan p-value 0.0168, yang signifikan pada tingkat 5%. Hal ini menunjukkan bahwa terdapat komponen varians residual yang dapat diandalkan. Namun, koefisien untuk lag varians (L(ehatsq)) tidak signifikan ($p = 0.793$), yang berarti bahwa lag dari varians tidak memberikan kontribusi yang berarti dalam memprediksi volatilitas. Kemudian dilakukan pengujian ARCH, yang menghasilkan p-value masing-masing

0.074269 untuk lag 1 dan 0.5768 untuk lag 2. Kedua hasil ini menunjukkan tidak ada bukti signifikan untuk adanya efek ARCH, mengindikasikan bahwa data tidak menunjukkan volatilitas bersyarat. Dalam model GARCH, konstanta (a_0) signifikan ($p < 0.001$), sedangkan koefisien untuk a_1 tidak signifikan ($p = 0.681$). Ini menunjukkan bahwa meskipun ada komponen varians yang signifikan, lag varians tidak memberikan informasi tambahan yang signifikan untuk model. Terakhir, hasil tes diagnostik menunjukkan bahwa residual tidak terdistribusi normal, dengan hasil tes Jarque-Bera yang memiliki p-value 0.0008418, mengindikasikan perlunya model yang lebih baik untuk menangkap karakteristik data. Namun, tes Box-Ljung untuk autokorelasi kuadrat residual menunjukkan p-value 0.88, yang berarti tidak ada autokorelasi signifikan dalam residual kuadrat.



Gambar 9. Plot Volatilitas Varians Residual dari Waktu ke Waktu

Dalam konteks ARCH, hasil plot yang ditunjukkan pada Gambar 9 menunjukkan bahwa varians bersyarat cenderung rendah pada sebagian besar periode, namun ada beberapa lonjakan besar yang terlihat pada sekitar titik 25 hingga 32. Ini menunjukkan adanya *volatility clustering* yaitu periode dimana varians tinggi diikuti oleh varians tinggi lainnya. Hal ini merujuk pada ketidakstabilan dalam waktu tertentu, yang mungkin disebabkan oleh perubahan eksternal atau kejadian tertentu dalam periode data tersebut. Model ARCH dirancang untuk menangkap pola volatilitas yang bervariasi ini, sehingga dapat digunakan untuk memprediksi volatilitas di masa depan.

Kesimpulan

Metode ARCH (Autoregressive Conditional Heteroskedasticity) merupakan metode statistik yang digunakan untuk menganalisis data deret waktu dengan menunjukkan fluktuasi dalam volatilitas. Metode ini cocok untuk menangkap pola volatilitas bersyarat, yang varians data berubah seiring waktu tergantung pada informasi residual sebelumnya. Pada metode ini dilakukannya analisis tingkat inflasi Indonesia dari Januari 2020 hingga Desember 2023 menggunakan metode ARIMA dan ARCH menunjukkan bahwa model ARIMA (3,1,0) dengan nilai AIC dan BIC terendah adalah yang terbaik untuk menangkap pola utama inflasi. Selanjutnya model ARCH diterapkan untuk memahami pola volatilitas, yang penting bagi prediksi inflasi yang lebih stabil. Kombinasi ARIMA dan ARCH berhasil memodelkan tren inflasi serta fluktuasi volatilitas, membantu dalam memberikan peramalan inflasi yang lebih akurat.

References

- [1] D. H. Hopfe, K. Lee, and C. Yu, "Short-term forecasting airport passenger flow during periods of volatility: Comparative investigation of time series vs. neural network models," *J Air Transp Manag*, vol. 115, p. 102525, Mar. 2024, doi: 10.1016/j.jairtraman.2023.102525.
- [2] Y. Lai and D. A. Dzombak, "Use of the Autoregressive Integrated Moving Average (ARIMA) Model to Forecast Near-Term Regional Temperature and Precipitation," *Weather Forecast*, vol. 35, no. 3, pp. 959–976, Jun. 2020, doi: 10.1175/WAF-D-19-0158.1.
- [3] M. Eliades, A. Bruggeman, H. Djuma, C. Christofi, and C. Kuells, "Quantifying Evapotranspiration and Drainage Losses in a Semi-Arid Nectarine (*Prunus persica* var. *nucipersica*) Field with a Dynamic Crop Coefficient (K_c) Derived from Leaf Area Index Measurements," *Water (Basel)*, vol. 14, no. 5, p. 734, Feb. 2022, doi: 10.3390/w14050734.
- [4] S. R. Rahman, "Penerapan Model ARCH pada Data Keuangan di Indonesia," *J. Matematika*, vol. 8, no. 1, pp. 15-25, 2016. doi: 10.24014/jsms.v7i2.13138.
- [5] K. L. A. Nastiti dan A. Suharsono, "Analisis Volatilitas Saham Perusahaan Go Public dengan Metode ARCH-GARCH," *Jurnal Sains dan Seni ITS*, vol. 1, no. 1, pp. 1-8, 2012. doi: 10.12962/j23373520.v1i1.2030.